
En el container de Nifi, crear un .sh que permita descargar el archivo de https://dataengineer-edvai.s3.amazonaws.com/yellow_tripdata_2021-01.parquet y lo guarde en /home/nifi/ingest. Ejecutarlo

```
nifi@1b48bdded3ce:~/ingest/tripdata$ sh ingest.sh
 -2023-04-11 20:31:37-- https://data-engineer-edvai.s3.amazonaws.com/yellow tri
pdata 2021-01.parquet
Resolving data-engineer-edvai.s3.amazonaws.com (data-engineer-edvai.s3.amazonaws
.com)... 52.217.204.81, 52.216.143.68, 3.5.17.191, ...
Connecting to data-engineer-edvai.s3.amazonaws.com (data-engineer-edvai.s3.amazo
naws.com) | 52.217.204.81 | :443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 21686067 (21M) [application/x-www-form-urlencoded]
Saving to: '/home/nifi/ingest/tripdata/yellow_tripdata_2021-01.parquet'
                                                        100%[======
yellow tripdata 2021-01.parquet
  ______
                                          20.68M 40.9MB/s
  ==========>|
                                                             in 0.5s
2023-04-11 20:31:37 (40.9 MB/s) - '/home/nifi/ingest/tripdata/yellow_tripdata_20
21-01.parquet' saved [21686067/21686067]
nifi@1b48bdded3ce:~/ingest/tripdata$ ls
ingest.sh yellow_tripdata_2021-01.parquet
nifi@1b48bdded3ce:~/ingest/tripdata$
```

2) Por medio de la interfaz gráfica de Nifi, crear un job que tenga dos procesos. a) GetFile para obtener el archivo del punto 1 (/home/nifi/ingest) b) putHDFS para ingestarlo a HDFS (directorio nifi)



```
hadoop@0485e86b7577:~$ hdfs dfs -ls /nifi
Found 2 items
-rw-r--r-- 1 nifi supergroup 182386 2023-04-11 17:43 /nifi/starwars.csv
-rw-r--r-- 1 nifi supergroup 21686067 2023-04-11 18:08 /nifi/yellow_tripdata_2021-01.parquet
hadoop@0485e86b7577:~$
```

- 3) Con el archivo ya ingestado en HDFS/nifi, escribir las consultas y agregar captura de pantalla del resultado. Para los ejercicios puedes usar SQL mediante la creación de una vista llamada yellow_tripdata. También debes chequear el diccionario de datos por cualquier duda que tengas respecto a las columnas del archivo https://www.nyc.gov/assets/tlc/downloads/pdf/data_dictionary_trip_records_yellow.pdf
- 3.1) Mostrar los resultados siguientes a. Vendorld Integer b. Tpep_pickup_datetime date c. Total_amount double d. Donde el total (total_amount sea menor a 10 dólares)

```
>> df2 = spark.sql("select VendorID, tpep_pickup_datetime, total_amount from tripdata WHERE total_amount < 10")
|VendorID|tpep_pickup_datetime|total_amount|
              1 2020-12-31 21:51:20
                                                                             4.3
              2 | 2020-12-31 21:42:11 |
2 | 2020-12-31 21:04:21 |
                                                                            8.3
                                                                           9.96
              2 | 2020-12-31 21:43:41
2 | 2020-12-31 21:36:08
1 | 2020-12-31 21:03:13
1 | 2020-12-31 21:30:32
2 | 2020-12-31 21:16:19
                                                                            9.3
                                                                             5.8
                                                                             0.0
                                                                             9.8
             2 | 2020-12-31 21:10:19|
2 | 2020-12-31 21:57:26|
2 | 2020-12-31 21:33:33|
2 | 2020-12-31 21:39:08|
2 | 2020-12-31 21:45:29|
1 | 2020-12-31 21:45:29|
                                                                           9.96
|
| 9.3
|
| 7.8
                                                                           9.55
                  2020-12-31 21:52:28
2020-12-31 21:39:50
                                                                             4.8
                                                                             9.8
             2 | 2020-12-31 21:39:39:39:39:2020-12-31 21:49:10|
2 | 2020-12-31 21:49:51|
2 | 2020-12-31 21:47:51|
2 | 2020-12-31 21:11:53|
                                                                             8.8
                                                                             7.8
                                                                           9.36
               1 2020-12-31 21:34:38
only showing top 20 rows
```

3.2) Mostrar los 10 días que más se recaudó dinero (tpep_pickup_date time, total_amount)

3.3) Mostrar los 10 viajes que menos dinero recaudó en viajes mayores a 10 millas (trip_distance, total_amount)

3.4) Mostrar los viajes de más de dos pasajeros que hayan pagado con tarjeta de crédito (mostrar solo las columnas trip distance y tpep pickup datetime)

```
>> df5 = spark.sql("select trip_distance,CAST(tpep_pickup_datetime as DATE) from tripda
ta WHERE passenger count >= 2")
>>> df5.show()
|trip_distance|tpep_pickup_datetime|
            2.7|
6.11|
                                2020 - 12 - 31 |
                               2020 - 12 - 31
            1.21
7.4
1.7
                               2020 - 12 - 31
2020 - 12 - 31
                               2020-12-31
                               2020 - 12 - 31
            0.81
                               2020-12-31
            1.66
                               2020-12-31
            0.93
                               2020 - 12 - 31
2020 - 12 - 31
            1.16
            19.1
                               2020 - 12 - 31
2020 - 12 - 31
            3.15
            0.64
             3.0
                               2020-12-31
           10.74
                               2020 - 12 - 31
                               2020-12-31
             1.0
            2.01
                               2020-12-31
            3.45
                                2020 - 12 - 31
                               2020-12-31
            2.85
                               2020 - 12 - 31 |
2020 - 12 - 31 |
            1.68
            0.77|
only showing top 20 rows
```

3.5) Mostrar los 7 viajes con mayor propina en distancias mayores a 10 millas (mostrar campos tpep_pickup_datetime, trip_distance, passenger_count, tip_amount)

```
>>> df6 = spark.sql("select trip_distance, CAST(tpep_pickup_datetime as DATE), passenger
_count, tip_amount from tripdata WHERE trip_distance > 10 ORDER BY tip_amount DESC LIMIT
>>> df6.show()
|trip_distance|tpep_pickup_datetime|passenger_count|tip_amount|
            427.7|
267.7|
                                   2021-01-20|
                                                                   1.0|
                                                                             1140.44|
                                                                                369.4
                                   2021-01-03
                                                                   1.0
                                  2021 - 01 - 12 |
2021 - 01 - 19 |
            326.1
260.5
                                                                   0.0
                                                                               192.61
                                                                   1.0
                                                                               149.03
                                                                                100.0
                                   2021-01-31
                                                                   0.0
             11.1j
                                   2021-01-01
                                                                   2.0
                                                                                 99.0
            14.86|
                                                                   0.0
                                   2021-01-18
                                                                                 90.0
              13.0|
```

3.6) Mostrar para cada uno de los valores de RateCodeID, el monto total y el monto promedio. Excluir los viajes en donde RateCodeID es 'Group Ride'